目录

前言 vii

第一部分　上岗前的基本功：最少必要的数学与工具 1

第一章　计算机基础 3
1.1 本章导读：为什么先讲这些基本功 . . . 3
1.2 Linux 基础与远程开发环境：你的工位在哪 . . . 5
1.3 你需要的 Python，不是教科书里那种 Python . . . 9
1.4 Python 环境管理：为什么别人能跑你跑不了 . . . 13
1.5 PyTorch：深度学习的第一个工具 . . . 20
1.6 数据长什么样：JSON、JSONL 与常见数据格式 . . . 33
1.7 Git 生存指南：代码后悔药与协作神器 . . . 40
1.8 浮点数常识：计算机是怎么存小数的 . . . 44
1.9 显卡与 CUDA 常识：你的算力底座 . . . 59

第二章　入门大模型需要的最少必要数学知识 73
2.1 本章导读：你需要多少数学 . . . 73
2.2 线性代数：为什么大模型眼里一切都是向量 . . . 74
2.3 微积分：模型是怎么知道该往哪儿改的 . . . 86
2.4 概率论：大模型如何处理不确定性 . . . 96

第三章　你的开源武器库：Hugging Face 生态 107
3.1 Hugging Face：开源模型世界的入口 . . . 107
3.2 开源模型江湖：常见的开源大模型 . . . 112
3.3 三行代码跑通你的第一个模型 . . . 116
3.4 Tokenizer 入门：文字是怎么变成数字的 . . . 123
3.5 下载下来的模型文件夹里都有什么 . . . 132
3.6 怎么在 Hugging Face 上快速判断一个模型能不能用 . . . 138

第二部分　深度学习基础：模型是怎么学会的 145

第四章　机器到底是怎么学习的？ 147
4.1 神经网络的基本零件：权重与偏置 . . . 147
4.2 激活函数：为什么光做线性变换不够 . . . 159

4.3 前向传播：数据从输入到输出走了一条什么路 170
4.4 Embedding 层：词怎么变成向量 178

第五章 损失函数与梯度下降 189
5.1 损失函数：机器怎么知道自己错得有多离谱 189
5.2 Softmax：从分数到概率分布的桥梁 197
5.3 交叉熵：文本生成任务里的损失函数 208
5.4 梯度下降：蒙着眼睛下山，怎么走到谷底 218
5.5 学习率：步子迈多大是门学问 230

第六章 误差是怎么传回去的？ 241
6.1 反向传播与链式法则：误差一层层甩锅的机制 241
6.2 优化器演进：从 SGD 到 Adam 254
6.3 训练中的常见问题：过拟合与正则化 269

第七章 Transformer 之前：深度学习走过的路 287
7.1 大模型的五个历史时刻 287
7.2 CNN：让机器学会看图的第一个真正有效的方案 300
7.3 RNN：一个王朝的兴衰 313

第三部分 大模型的心脏：彻底解构 Transformer 323

第八章 注意力机制：大模型为什么能懂上下文？ 325
8.1 注意力的直觉：打分与加权平均 325
8.2 Q、K、V：注意力分数到底是怎么算出来的 335
8.3 多头注意力：为什么要从不同角度看同一句话 347

第九章 顺序与距离：Transformer 怎么理解位置 357
9.1 位置编码：不用 RNN，怎么让模型知道词的先后顺序 357
9.2 旋转位置编码：大模型怎么编码相对位置 367
9.3 位置编码外推：模型怎么读更长的文本 375

第十章 Transformer Block：一层模型内部怎么工作 385
10.1 残差连接：为什么深层 Transformer 训得动 385
10.2 为什么大模型每层都要做一次归一化 390
10.3 前馈网络：Transformer 里的记忆体 400
10.4 一层 Transformer 内部的数据流 410

第十一章 从 Transformer 到大模型：架构选型与输出机制 421
11.1 Encoder、Decoder 和掩码机制：谁能看见谁 421
11.2 为什么现在的大模型都选 Decoder-only 432
11.3 从隐藏向量到下一个词：大模型的最后一步 440
11.4 Transformer 全面总结：一个 token 从输入到输出的完整旅程 449

第十二章 Transformer 的进化：当模型越来越大、越来越杂 463
12.1 MoE：不是所有参数每次都要用 463
12.2 万物皆可向量：从 Embedding 思想到 ViT 与 CLIP 477
12.3 多模态大模型：图片和文字是怎么融合在一起的 489
12.4 扩散模型：AI 是怎么生成图片的 503

第四部分 训练与调优：让模型学会按要求工作 513

第十三章 不改参数也能干活：Prompt Engineering 与上下文学习 515
13.1 解码策略：模型怎么生成文字 515
13.2 Prompt Engineering：别让模型答非所问 531
13.3 结构化输出：怎么让大模型稳定地输出 JSON 545

第十四章 大模型的出厂与深造：预训练与指令微调 561
14.1 预训练：读书破万卷，读的到底是什么 561
14.2 指令微调：怎么把读书人变成打工人 572
14.3 从零跑通一个指令微调任务 584

第十五章 高效微调：LoRA 的直觉与实战 601
15.1 LoRA 的核心思想：冻结大矩阵，外挂小矩阵 601
15.2 LoRA 实战：用最精简的代码跑通微调任务 612

第十六章 多卡训练：一张卡装不下之后怎么办 625
16.1 梯度累积与数据并行：显存不够、训练太慢时怎么办 625
16.2 ZeRO：消除多卡之间的冗余 630
16.3 张量并行与流水线并行：模型太大装不下怎么办 638

第十七章 对齐与强化学习：怎么让模型知道什么是更好的回答？ 647
17.1 为什么需要对齐 647
17.2 PPO：怎么给模型找一个打分老师 654
17.3 DPO：抛开奖励模型，直接用偏好数据训练 670
17.4 GRPO：用规则代替人工打分 683

第五部分 应用与落地：让大模型好用又能打 697

第十八章 不改模型也能补知识：RAG 699
18.1 RAG 的原理：为什么要先检索再生成 699
18.2 从零搭建一个最小 RAG 系统 714

第十九章 让大模型学会动手：Agent 727
19.1 Function Calling：从回答问题到完成任务 727
19.2 ReAct：让模型边想边做 739
19.3 MCP 与 Skills：给 Agent 装上工具箱和资料库 754

第二十章 推理加速与成本控制 **767**
20.1 KV Cache：为什么生成第 100 个词不需要重新算前 99 个词 767
20.2 模型量化：怎么把大模型塞进小显存 776
20.3 模型蒸馏：让小模型学会大模型 789
20.4 显存估算实战：跑一个模型到底需要多少显存 800
20.5 模型部署基础：怎么把模型变成一个 API 服务 813

第二十一章 模型评估：怎么证明模型真的变好了？ **823**
21.1 分类任务的评估：准确率、精确率、召回率、F1 823
21.2 自动评估指标：困惑度、ROUGE、BLEU 和它们的局限 834
21.3 Benchmark 与排行榜：分数到底能不能信 848
21.4 人工评估与 LLM Judge：没有标准答案时怎么判断好坏 860

第六部分 泥潭求生：数据工程的脏活累活 **873**

第二十二章 算法工程师的数据全景 **875**
22.1 算法工程师的日常真相：大部分时间都在和数据打交道 875
22.2 大模型需要什么数据：SFT、偏好、评测与 RAG 知识库 877
22.3 高质量数据从哪来：开源、内部、采购与合成 891
22.4 合成数据：用大模型造数据喂大模型 906
22.5 合成数据的后半场：怎么过滤、怎么避坑、怎么用对 917
22.6 数据安全与合规：算法工程师必须知道的红线 929
22.7 拿到数据的第一眼：先自己看一遍 936
22.8 数据配比：不同类型的数据该怎么混 948

第二十三章 数据标注的全流程：从构造到质检 **961**
23.1 指令微调数据的标注：怎么定义好回答 961
23.2 偏好数据的标注：怎么让标注员分出更好和更差 974
23.3 标注完的数据，你凭什么相信它 988

第二十四章 数据迭代与飞轮 **999**
24.1 从 bad case 到行动：拿到问题之后该干什么 999
24.2 内部 Benchmark 的构建与维护 1010
24.3 数据版本管理：给数据留一颗后悔药 1024
24.4 数据飞轮：用模型的能力反哺数据生产 1034
24.5 一个完整的迭代周期长什么样 1048

第七部分 把技术变成作品 **1061**

第二十五章 做一个能写进简历的项目 **1063**
25.1 项目从哪里开始 1063
25.2 怎么把教程变成你自己的项目 1068
25.3 课题、比赛和毕设：不是只有教程才能变成项目 1074
25.4 项目做完以后，怎么整理成一个作品 1078

第八部分　不只是写代码：算法工程师的职场生存　1083

第二十六章　你的队友们：认识团队里的每个角色　1085

26.1 谁是谁？算法工程师周围的角色地图 1085
26.2 和产品经理打交道：先把需求边界说清楚 1092
26.3 和测试工程师打交道：出了问题到底算谁的 1101
26.4 和项目经理打交道：排期、资源协调与进度同步 1111
26.5 互联网黑话生存指南 1120

第二十七章　向上管理：让工作被看见　1127

27.1 让 leader 知道你在干什么、干得怎么样 1127
27.2 让 leader 给你资源：算力、人力、标注预算怎么申请 1137

第二十八章　工作交接：屎山之间的传承　1149

28.1 接手别人的工作 1149
28.2 把你的工作交接给别人 1159

第九部分　求职与破局：拿到属于你的那张船票　1167

第二十九章　面试这件事　1169

29.1 AI 行业到底有哪些岗位 1169
29.2 看懂一条 JD：公司到底想招什么人 1177
29.3 简历怎么写、往哪投 1183
29.4 笔试与算法题 1192
29.5 八股题：怎么准备才不是死背 1200
29.6 项目经验题：怎么把你做过的事讲成一个好故事 1208

第三十章　反向背调：这个 offer 值不值得接　1219

30.1 面试时怎么反向收集信息 1219
30.2 拿到 offer 之后怎么做最终决策 1227
30.3 离职与跳槽：既是终点，也是起点 1234

第三十一章　入行之后：持续跟上，也保持清醒　1241

31.1 入职前六个月 1241
31.2 怎么在这个领域持续跟上 1247
31.3 那些私信里反复出现的问题 1254
31.4 算法工程师的痛苦 1266

后记　1271

附录：第一章线上完整版核对稿　1273

31.5 Linux 基础与远程开发环境：你的工位在哪 1274
31.6 你需要的 Python，不是教科书里那种 Python 1293
31.7 数据长什么样：JSON、JSONL 与常见数据格式 1315
31.8 Git 生存指南：代码后悔药与协作神器 1326

附录：术语速查 **1341**